



Time Series Forecasting

时间序列预测项目

黄煜程 王—林 张讯毓

目录

01

概述

02

方法

04

实验

03

总结



01

概述

概述



时间序列预测（TSF）

时间序列预测是利用历史时间序列数据，建立数学模型，对未来某一时刻或某一时段的数据进行预测的任务。广泛应用于金融、能源、交通、气象等领域。其核心在于挖掘数据的趋势、季节性和随机性，并构建适合的预测模型。



项目任务

本项目聚焦于电力系统中的变压器温度预测任务。利用过去**96**个时间步的多变量历史数据，预测未来**24**个时间步的油温变化趋势。该任务的实际意义在于提前预警变压器过热风险，避免设备损坏和电网事故，从而优化电力系统的运维管理，降低经济损失。

数据集

ETT (Electricity Transformer Temperature)

简介：ETT数据集是中国某电力变压器上的关键数据记录，主要用于油温预测，这是电力系统健康监测的重要指标。

数据集	采样频率	时间跨度	特征数量	特点
ETTh1	1小时	2016.7-2018.7	7个特征	小时级，变压器1
ETTh2	1小时	2016.7-2018.7	7个特征	小时级，变压器2
ETTm1	15分钟	2016.7-2018.7	7个特征	分钟级，变压器1， 数据密集
ETTm2	15分钟	2016.7-2018.7	7个特征	分钟级，变压器2， 数据密集

数据集特点：

ETTh 系列：小时级采样，适合长期趋势预测

ETTm 系列：15分钟采样，数据量大，适合短期精细预测
不同变压器数据模式差异大，增加预测难度



02

方法

SARIMAX

SARIMAX 是传统统计学方法，全称为 **Seasonal AutoRegressive Integrated Moving Average with eXogenous factors**。它通过历史数据的自回归特性和移动平均来预测未来趋势，并考虑季节性周期和外生变量的影响。

三个核心成分：

AR (AutoRegressive)：利用过去 p 步的值预测当前值

I (Integrated)：通过 d 阶差分使非平稳序列变为平稳


MA (Moving Average)：利用过去 q 步的误差项预测当前值

季节部分

参数	含义
p	自回归阶数 AR
d	差分阶数 I
q	滑动平均阶数 MA

非季节部分

参数	含义
P	季节自回归阶数
D	季节差分阶数
Q	季节滑动平均阶数
s	季节周期（如：12=一年周期）



SARIMAX = 历史值 (AR) + 历史误差 (MA) + 季节项 + 外部变量


iTransformer

iTransformer (inverted Transformer)的最大创新在于将传统 Transformer 的注意力机制从**时间维度**转移到**变量维度**。每个时间点被视为一个 token，模型学习不同变量之间的复杂相关性，而非仅关注时间序列的自相关性。

超参数	含义
d_model	隐藏层维度
nhead	注意力头数
num_layers	编码器层数
dropout	Dropout 比例
learning_rate	学习率
batch_size	批次大小

优势：

捕捉变量间**复杂相关性**
并行计算，训练效率高
适合长序列预测



iTransformer 将「时间 × 特征」矩阵转置为「特征 × 时间」，把每一个变量当成一个 token，再进行自注意力计算。

Foundation Model — Chronos

Chronos 是由 **Amazon团队** 提出的一个面向时间序列的**预训练基础模型**，通过大规模预训练实现通用预测能力。

主要思路：

(1) 时间序列 → Token

Chronos 不直接处理原始数值，而是先将时间序列：

[120, 132, 128, 140, ...]

通过 **离散化 (Discretization)** 映射成：

Token_83, Token_91, Token_96, ...

然后像处理文本一样预测下一个Token


(2) 基于大规模预训练

Chronos 在大量时间序列数据上进行预训练，包括：

金融时间序列、电力负载、气候数据

通过这种方式，使其具备：

- Zero-shot forecasting (零样本预测)
- Few-shot forecasting (少样本微调)



“时间序列领域的 GPT”



03

实验

实验设置



数据集预处理

- 1.数据来源: ETT(Electricity Transforming Transformer)数据集
 - ETTm1/ETTM2: 中等尺度数据集, 采样频率15分钟
 - ETTh1/ETTh2: 高尺度数据集, 采样频率1小时
- 2.缺失数据处理: 使用前向填充(Forward Fill)方法填补缺失值
- 3.时间特征提取: 采用正弦-余弦变换提取时间特征
 - $\sin(2\pi \cdot t / \text{period})$ 和 $\cos(2\pi \cdot t / \text{period})$



数据集划分

- 训练集/验证集/测试集比例 = 6:2:2
- 划分方式:
 - `train_clip = int(len(df) * 0.6)`
 - `valid_clip = int(len(df) * 0.8)`
 - `train_df = df[:train_clip]`
 - `valid_df = df[train_clip:valid_clip]`
 - `test_df = df[valid_clip:]`



固定随机种子

- 实验种子: 42
- `lightning.seed_everything(42)`
- 确保实验的可重复性

实验设置



实验框架与配置

深度学习框架: PyTorch
Lightning

Python版本: 3.13.2

环境管理: Conda

日志记录: Weights & Biases
(wandb)

超参数搜索: Optuna (TPE算
法, 50 trials)

数据库: SQLite



训练配置

训练轮次: 50 epochs
(iTransformer10个)

验证策略: 每5个epoch在验证
集上验证一次

评价指标: MAE、MSE、
MAPE

预测方式: 迭代多步预测(IMS
- Iterative Multi-step)



评价指标定义

MAE(Mean Absolute Error) =
 $(1/n) \cdot \sum |y_t - \hat{y}_t|$

MSE(Mean Squared Error) =
 $(1/n) \cdot \sum (y_t - \hat{y}_t)^2$

MAPE(Mean Absolute
Percentage Error) = $(1/n) \cdot \sum |y_t$
 $- \hat{y}_t| / |y_t|$

实验结果


MAE Comparison of Three Methods on Four Datasets

Methods	ETTh1	ETTh2	ETTm1	ETTm2
SARIMAX	3.9641	4.7136	3.6666	4.6987
iTransformer	0.0028	0.0120	0.0005	0.0020
Chronos	2.1905	6.4112	1.3896	4.5114

方法对比：
iTransformer: 精度最高，但需要更多训练数据和计算资源
Chronos: 性能中等，但在某些数据集上表现良好
SARIMAX: 传统统计方法，可解释性强但精度有限

实验结果

Prediction Curves Comparison (Ground Truth vs Three Methods)



实验结果

整体趋势：

1. iTransformer (绿色虚线) ** - 最贴近真实曲线，波动小，跟随性好
2. Chronos (红色虚线) ** - 能够捕捉总体趋势，但在细节处有偏差
3. SARIMAX (蓝色虚线) ** - 波动较大，在某些时间段偏离真实值较多

关键观察：

iTransformer在所有时间点都保持稳定的预测精度

Chronos对于长期趋势把握较好，但短期波动捕捉不足

SARIMAX作为传统方法，在复杂时间序列上存在局限性

预测质量评估：

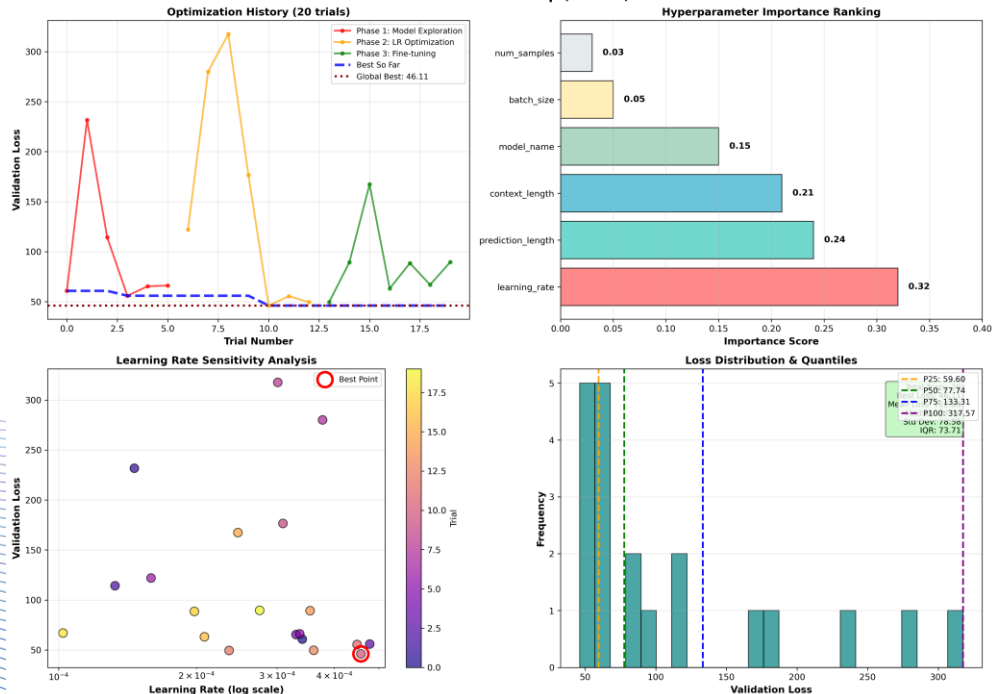
最佳拟合: iTransformer - 曲线最平滑且最接近真实值

次优表现: Chronos - 总体趋势正确但细节欠缺

改进空间大: SARIMAX - 需要更复杂的模型结构

实验调参说明

Chronos Hyperparameter Tuning Analysis - ETTm2
Load Transformer Temp (15-min)




搜索空间:

- model_name: ['google/t5-efficient-tiny', 'google/t5-efficient-mini', 'google/t5-efficient-small']
- context_length: [256, 512, 1024]
- prediction_length: [24, 48, 96]
- seq_len: [48, 96, 192]
- batch_size: [16, 32, 64]
- learning_rate: [1e-5, 1e-3] # Log scale
- num_samples: [10, 30]
- 最大试验次数: 20
- 优化算法: TPE

实验调参说明





iTransformer Hyperparameter Tuning Analysis - ETTm2
Load Transformer Temp (15-min)



- 搜索空间:
 - d_model: [32, 64, 128]
 - nhead: [2, 4, 8]
 - num_layers: [2, 3, 4, 5]
 - dropout: [0.01, 0.2]
 - learning_rate: [1e-4, 1e-2]
- 优化算法: TPE

实验调参说明

SARIMAX Hyperparameter Tuning Analysis - ETTm2
Load Transformer Temp (15-min)



- 搜索空间:
 - p (AR阶数): [0, 3]
 - d (差分阶数): [0, 2]
 - q (MA阶数): [0, 3]
 - P (季节AR): [0, 2]
 - D (季节差分): [0, 2]
 - Q (季节MA): [0, 2]
 - s (周期): 96 (固定)
- 最大试验次数: 50
- 优化算法: TPE (Tree-structured Parzen Estimator)

实验调参说明

TPE算法在三种方法中均表现良好
能快速识别重要参数区间
适合混合类型(离散+连续)参数搜索

数据集: ETTm1 (15分钟频率)

维度	SARIMAX	iTransformer	Chronos
试验次数	50	50	22
最佳指标	损失2.0197	MAE 0.0010	损失18.721
最重要参数	差分阶数(d)	学习率	学习率
收敛速度	快(30次)	中(40次)	快(15次)
最优复杂度	简单	中等	轻量级(mini)



04

总结

实验总结和体会



在本次时间序列预测项目中，我们深入探讨了机器学习在电力系统中的应用。通过对比三种不同的方法——**SARIMAX**、**iTransformer** 和 **Chronos**，我们不仅学习了各自的理论基础和实现方式，还理解了它们在实际应用中的优缺点。

SARIMAX 作为传统的统计模型，强调了时间序列数据的自回归和移动平均特性，适合处理具有**明显季节性和趋势**的数据。它的**可解释性强**，但在处理复杂的非线性关系时显得力不从心。

iTransformer 代表了深度学习在时间序列预测中的创新应用。通过引入**注意力机制**，它能够有效捕捉变量间的复杂关系，尤其适合**多变量时序数据**的建模。尽管其训练过程较为复杂，但在大数据量的情况下表现优异。

Chronos 则展示了预训练模型在时间序列预测中的潜力。它的零样本学习能力使得在**数据量不足**的情况下仍能进行有效预测，适合快速原型设计和多领域应用。

通过这次项目，我们不仅掌握了时间序列预测的基本理论，还提高了对不同模型的理解和应用能力。

不足



模型泛化能力

在某些情况下，模型在训练集上表现良好，但在验证集和测试集上却出现了过拟合现象。未来需要加强对模型泛化能力的研究，探索更有效的正则化方法



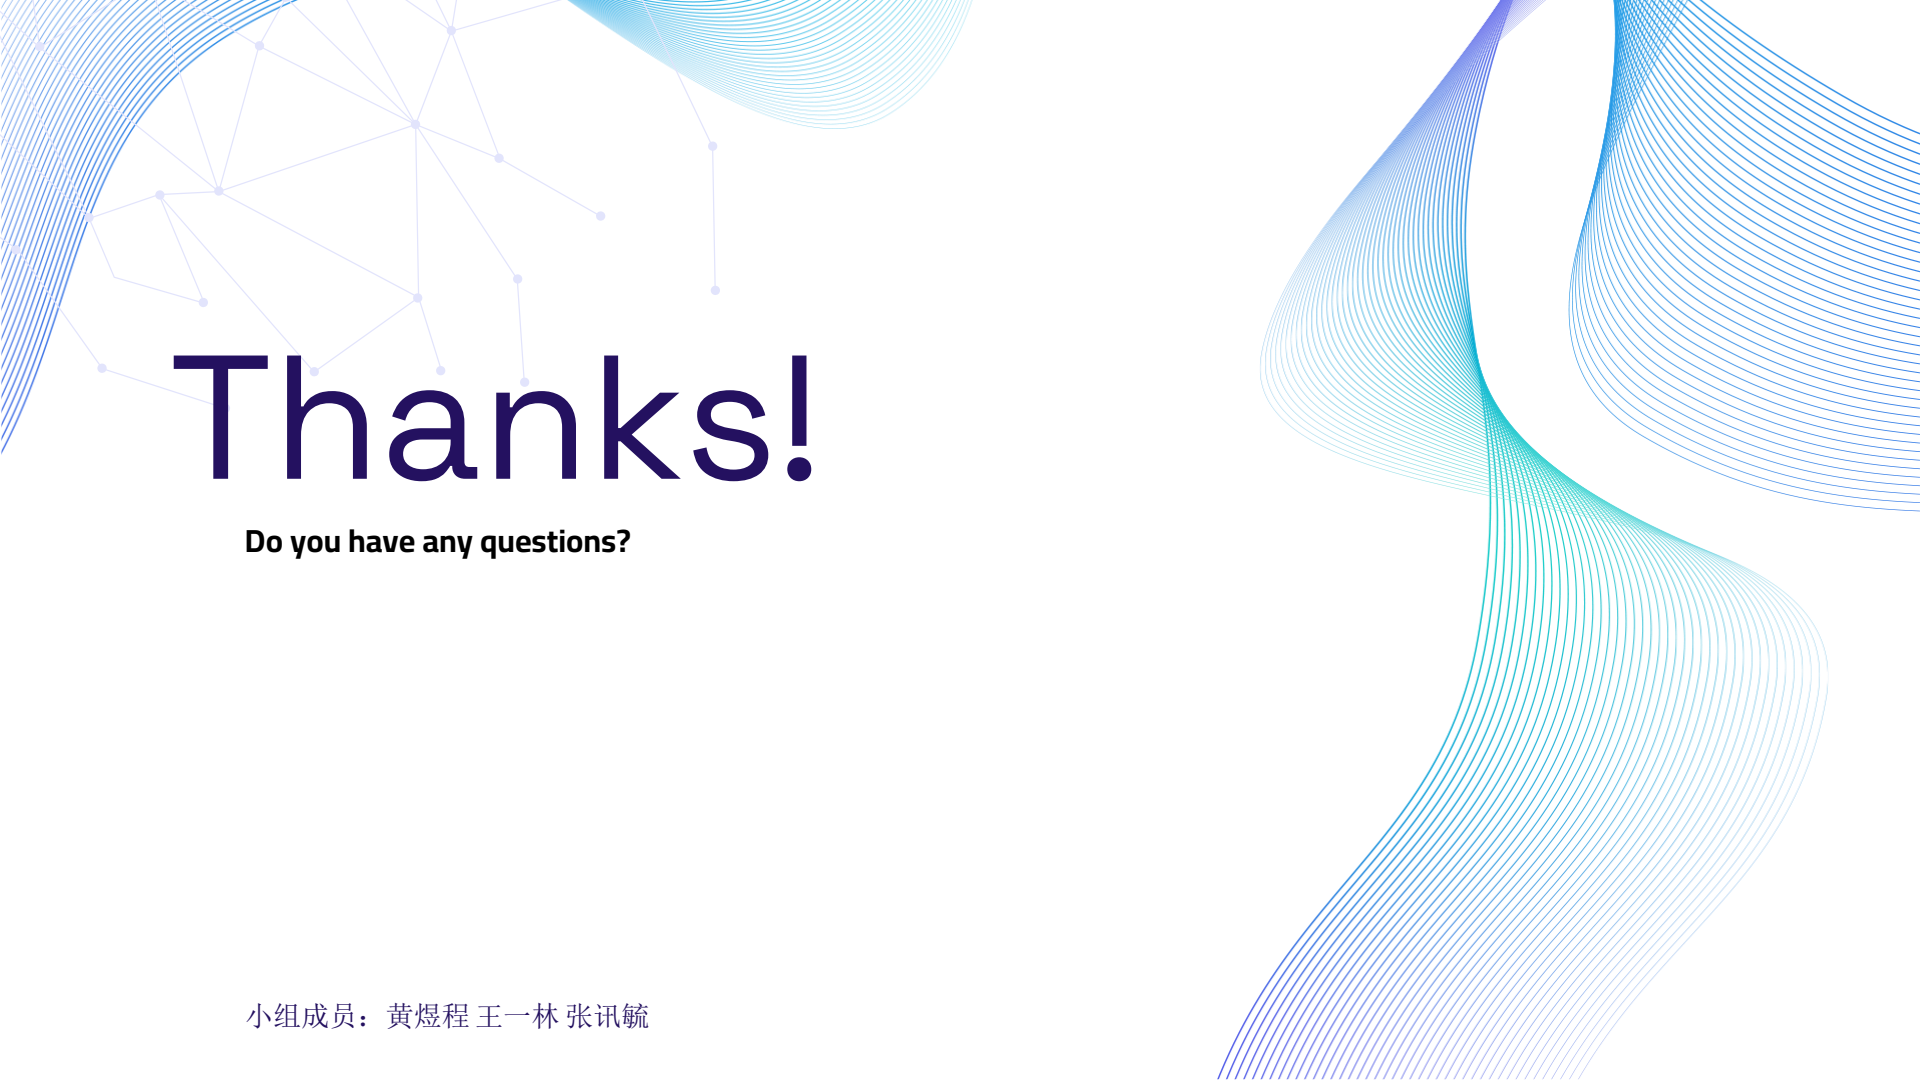
对异常值的处理

在数据集中，存在一些异常值对模型预测造成了干扰。未来可以考虑引入更为复杂的异常值检测和处理机制，以提高模型的鲁棒性



文献研究的深度

在方法选择和实现过程中，我们对相关文献的研究还不够深入，未来可以加强对最新研究成果的学习，以便更好地应用于实际项目中



Thanks!

Do you have any questions?

小组成员：黄煜程 王一林 张讯毓